

# Tema 2 MN

---

**Autor:** Trifan Bogdan-Cristian (312 CD)

Acest proiect abordează metode numerice fundamentale pentru procesarea imaginilor, punând accent pe **compresie** și **recunoaștere de pattern-uri**. Prin implementarea algoritmilor pe imagini alb-negru și pe **setul de date MNIST**, am explorat atât fundamente teoretice (**SVD**, **PCA**), cât și aplicații practice (clasificarea cifrelor scrise de mână).

## Task 1 – Compresia imaginilor cu SVD

Am implementat compresia unei imagini prin **descompunerea valorilor singulare** (**SVD**).

Pași:

1. se calculează factorizarea ( $A = U S V^T$ ),
2. se păstrează doar primii  $k$  vectori și valori singulare,
3. se reconstruiește matricea aproximativă ( $A_k$ ).

**Observație:** reducerea lui  $k$  duce la o compresie mai bună, dar cu pierdere vizibilă de detaliu. Există un prag optim unde imaginea păstrează claritatea, dar ocupă mult mai puțină memorie.

## Task 2 – PCA cu SVD

Am aplicat **analiza componentelor principale** folosind **SVD** pentru a reduce dimensiunea datelor.

Pași principali:

1. normalizarea datelor,
2. calcularea **SVD** asupra matricii standardizate,
3. proiectarea imaginilor pe un spațiu cu mai puține dimensiuni ( $pcs$ ),
4. reconstrucția imaginii.

**Observație:** rezultatele sunt similare cu Task 1, dar **PCA** oferă o **interpretare mai intuitivă** asupra direcțiilor de variație maximă.

## Task 3 – PCA cu matricea de covarianță

Am repetat algoritmul **PCA**, de această dată folosind **matricea de covarianță și valorile/vectorii proprii**.

Metodologia urmează pașii clasici:

1. calcularea mediei și centrarea datelor,
2. construirea matricii de covarianță,
3. diagonalizarea acesteia,
4. selecția celor mai relevante componente.

**Observație:** rezultatele reconstrucției sunt echivalente cu metoda bazată pe **SVD**, dar costul computațional poate fi diferit în funcție de dimensiunea datelor.

## Task 4 – Recunoașterea cifrelor scrise de mână

Am abordat problema **digit recognition** pe **setul MNIST** (60.000 imagini de antrenament, 28x28 pixeli).

Implementare:

1. pregătirea și normalizarea datelor,
2. aplicarea **PCA** pentru reducerea dimensionalității (la ~23 componente),
3. clasificarea folosind algoritmul **k-nearest neighbours** ( $k = 5$ )

**Rezultat:** algoritmul obține o acuratețe de aproximativ **93%**, un compromis între simplitate și performanță.

**Observație:** deși nu atinge precizia rețelelor neuronale (>98%), metoda **PCA + kNN** are **avantajul clarității** și a **timpului de rulare mai redus**.

## Concluzii

- **SVD** și **PCA** reprezintă instrumente esențiale în reducerea dimensionalității și compresia datelor vizuale.
- Am observat empiric cum numărul de componente influențează direct calitatea reconstrucției
- Recunoașterea cifrelor prin **PCA + kNN** demonstrează puterea metodelor numerice „clasice” în machine learning, chiar și în fața unor probleme moderne

Proiectul îmbină teoria matematică cu aplicații practice, oferind o perspectivă clară asupra modului în care metodele numerice fundamentează algoritmi de procesare a imaginilor și clasificare.